Apprentissage Statistique

Exercice du diapo

S1-2023

1 Supervised classification

1.1 Excercice

Exercice 1:

$$\begin{split} L* &= 1 - P(g*(X) = Y) \\ &= 1 - \mathbb{E}[g*(X) = 1]P(Y = 1|X) \\ &= 1 - \mathbb{E}[\mathbbm{1}_{P(Y = 1|X)} + \mathbbm{1}_{g*(X) = 0}P(Y = 0|X)] \\ &= 1 - \mathbb{E}[\mathbbm{1}_{\eta(X) > 1/2}\eta(X) + \mathbbm{1}_{\eta(X) \le 1/2}(1 - \eta(X))] \end{split}$$

Exercice 2

$$\begin{split} L* &= 1 - P(g*(X) = Y) \\ &= 1 - \mathbb{E}[P(g*(X) = Y|X)] \\ &= 1 - \mathbb{E}[\max(1 - \eta(X), \eta(X))] \\ &= 1 + \mathbb{E}[\min(\eta(X) - 1, -\eta(X))] \\ &= \mathbb{E}[\min(\eta(X), 1 - \eta(X))] \end{split}$$

Exercice 3: Si L*(X)=0 ça veut dire que c'est un processus déterministe. Que Y a un lien déterministe avec X

$$P(g*(X) \neq Y) = 0 \Rightarrow Y = g*(X)as..$$

$$Y = \phi(X) \Rightarrow P(Y \neq \phi(X)) = 0 \Rightarrow L* = 0.$$

1.2 Statistical Learning

Exercice diapo 18 : $consistency \Leftrightarrow L(g_n) \to^{L^1} L* \Leftrightarrow L(g_n) \to^{\mathbb{P}} L*$

• Pour la convergence L1 (je crois)

$$P(g_n(X) \neq Y | \mathcal{D}_n) \to^{L1} L*$$

$$\mathbb{E}[P(g_n(X) \neq Y | \mathcal{D}_n) - L*]$$

$$= \mathbb{E}[P(g_n(X) \neq Y [\mathcal{D}_n) - L*])]$$

$$= P(g_n(X) \neq Y) - L*$$

$$\to 0(?)$$

· Pour la convergence en proba dans le sens non instinctif, on veut montrer que

$$Z_n \to^{\mathbb{P}} 0$$
 $|Z_n| \le 1 \text{ car proba}$
alors $Z_n \to^{L1} 0$

Preuve:

$$\mathbb{E}[|Z_n|] = \mathbb{E}[Z_n|\mathbb{1}_{|Z_n|>\epsilon}] + \mathbb{E}[Z_n|\mathbb{1}_{|Z_n|\le\epsilon}]$$

$$\leq P(|Z_n|>\epsilon)$$

1.3 Exercice TD

1.3.1 **Exercice 1**

$$(X,Y) \in \mathbb{R} \times [0,1], X \sim \mathcal{U}([-2,2]), ect$$

$$\begin{split} Y &= \mathbbm{1}_{X < 0, U \le 2} + \mathbbm{1}_{X > 0, U > 1} \\ \eta &= P(Y = 1 | X) \\ &= P(X < 0, u \le 2 | X) + P(X > 0, U > 1 | X) \\ &= \mathbbm{1}_{X < 0} P(U \le 2) + \mathbbm{1}_{X > 0} P(U > 1) \\ &= \mathbbm{1}_{X < 0} \frac{2}{10} + \mathbbm{1}_{X > 0} \frac{9}{10} \end{split}$$

$$g * (X) = \mathbb{1}_{\eta(X) > \frac{1}{2}} = \mathbb{1}_{X > 0}$$

Bayes error

$$\begin{split} L* &= P(g*(X) \neq Y) \\ &= \frac{1}{2} - \frac{1}{2}\mathbb{E}[|2\eta(X) - 1|] \\ &= \frac{1}{2} - \frac{1}{2}\mathbb{E}[\left|\frac{4}{10}\mathbbm{1}_{X < 0} + \frac{18}{10}\mathbbm{1}_{X > 0} - 1\right|] \\ &= \frac{1}{2} - \frac{1}{2}\mathbb{E}[\left|\frac{6}{10}\mathbbm{1}_{X < 0} + \frac{8}{10}\mathbbm{1}_{X > 0}\right|] \\ &= \frac{1}{2} - \frac{1}{2}*\frac{6}{10}*\frac{1}{2} - \frac{1}{2}*\frac{8}{10}*\frac{1}{2} \\ &= \frac{3}{20} \end{split}$$

1.3.2 Exercice 2

1.

$$L* = \mathbb{E}[\min(\eta(X), 1 - \eta(X))]$$
$$= \mathbb{E}[\min(\frac{x}{c+x}, \frac{c}{c+x})]$$
$$= \mathbb{E}[\frac{\min(x, c)}{c+x}]$$

$$2. f_x(x) = \frac{\mathbb{1}_{x \in [0, \alpha c]}}{\alpha c}$$

$$L* = \int_0^{\alpha c} \frac{\min(x, c)}{x + c} \frac{dx}{\alpha c}$$
$$= \int_0^c \frac{x}{x + c} \frac{dx}{\alpha c}$$
$$= \frac{1}{\alpha} \log(\frac{(\alpha + 1)e}{4})$$

- 3. exercice, étudier la fonction ou
 - f continue sur $[1, +\infty]$
 - $\lim_{\alpha \to \infty} f(\alpha) = 0$

Doch f admet un maximum

1.3.3 Exerice 3

 $X \sim (T,B,E) \sim \mathcal{E}(1)$ densité d'une loi exp $Z \sim \mathcal{E}(1)$

$$f_Z(z) = e^{-z \mathbb{1}_{\mathbb{R}_+}(z)}$$

$$F_Z(t) = (1 - e^{-t}) \mathbb{1}_{\mathbb{R}_+}(t)$$

$$G_z(t) = \mathbb{1}_{\mathbb{R}_-} + e^{-t} \mathbb{1}_{\mathbb{R}_+}(t)$$

1. Y est une fonction de X donc L*=0. C'est déterministe

2.

$$\begin{split} P(Y=1|T,B) &= P(T+B+E < 7|T,B) \\ &= F_Z(7-T-B) \operatorname{car} E \bot (T,B) \end{split} \\ &= (1-e^{-(7-T-B)}) \mathbb{1}_{7-T-B>0} \end{split}$$

3.

$$g^*(T,B) = \mathbb{1}_{\eta(T,B)>1/2}$$
$$\eta(T,B) > 1/2$$
$$\Leftrightarrow 1 - e^{T+B-7} > \frac{1}{2}$$
$$\Leftrightarrow -\ln 2 > T+B-7$$
$$\Leftrightarrow T+B < 7 - \ln 2$$

Donc $g * (T, B) = \mathbb{1}_{T+B < 7-\ln 2}$

4. $T, B \sim \mathcal{E}(1)$ et $T \perp B$ donc $T + B \sim \gamma(2, 1)$, $f_{T+B}(u) = ue^{-u} \mathbb{1}_{\mathbb{R}_+(u)}$

5.

$$\begin{split} L^* &= P(g^*(T,B) \neq Y) = P(g^*(T,B) = 1, Y = 0) + P(g^*(T,B) = 1, Y = 0) \\ &= P(T+B < 7 - \ln 2, T+B+E \ge 7) + P(T+B \ge 7 - \ln 2, T+B+E < 7) \\ &= a+b \\ a &= \mathbb{E}[P(T+B < 7 - \ln 2, T+B+3 \ge 7|T,B)] \\ &= \mathbb{E}[\mathbb{1}_{T+B < 7 - \ln 2}G(7-T-B)] \\ &= \mathbb{E}[\mathbb{1}_{T+B < 7 - \ln 2}e^{T+B-7}] \\ &= \int_0^{7 - \ln 2} e^{u-7}ue^{-u}du \\ &= e^{-7}[\frac{u^2}{2}]_0^{7 - \ln 2} \\ &= e^{-7}\frac{(7 - \ln 2)^2}{2} \\ b &= \text{same} \\ a+b &= e^{-7}(\frac{(7 - \ln 2)^2}{2} + 2(8 - \ln 2) - 8 - \frac{7^2}{2} + \frac{(7 - \ln 2)^2}{2}) \end{split}$$

6.

$$P(Y = 0) = P(T + B + E \ge 7)$$

$$= P(\gamma(3) \ge 7)$$

$$= \int_{7}^{+\infty} \frac{1}{2} u^{2} e^{-u} du$$

$$= 0.029$$