

Examen Réparti 1 : XAI

Durée 1h30

seul document autorisé : feuille A4 manuscrite

tout support électronique interdit

Le barème n'est donné qu'à titre indicatif.


Exercice 1 : Explications par exemples contre-factuels (3 points)

On souhaite générer des explications par exemples contre-factuels en utilisant l'algorithme Growing Spheres, en remplaçant la norme L2 (ou distance euclidienne) sur laquelle il repose par une distance euclidienne pondérée.

1. Quelle modification faut-il apporter à l'algorithme ?
2. Quel impact a cette modification ? Illustrer pour le cas de données en 2 dimensions, en représentant une frontière de décision, une donnée x^* dont on souhaite expliquer la prédiction et les exemples contre-factuels générés. Commenter et justifier les réponses.
3. Quelles peuvent être les motivations pour l'utilisation de cette distance pondérée ? Qu'est-ce qui peut guider le choix de ses poids ? A quel coût ?

Exercice 2 : Modèles de substitution (4 points)

On se place dans un espace à 2 dimensions X_1 et X_2 , dans un problème de classification binaire. Après application de l'algorithme de LORE, un arbre de décision a été construit dont la frontière de séparation des classes est représentée en rouge dans la figure ci-dessous. Dans cette figure, on note +1 la classe associée aux ronds, et -1 la classe associée aux carrés.



1. Donner la représentation graphique de l'arbre de décision associé à cette frontière de séparation.
2. On considère l'exemple de coordonnées (8, 5) représenté par la croix rouge sur la figure.
 - (a) Donner la classe donnée par l'arbre pour cet exemple.
 - (b) Quels sont les explications contrefactuelles candidates générées par LORE pour expliquer la décision prise ?
 - (c) Quelles explications seront produites par LORE à partir des exemples contrefactuels obtenus ?
 - (d) Si plusieurs explications sont produites par LORE, proposer une approche qui permet de n'en retenir qu'une seule.

Exercice 3 : Explications par scores d'importance locale (5 points)

1. Caractériser, en justifiant, les méthodes LIME, SHAP et gradients intégrés par rapport aux axes de discussion classiques des méthodes d'IA explicable : post-hoc ou ad hoc, agnostique aux données ou non, agnostique au modèle ou non, local vs global.
2. En quoi les valeurs calculées par SHAP peuvent être vues comme des explications de la prédiction faite par un classifieur ?
3. On considère un jeu coopératif à trois joueurs dont l'objectif est de former des paires de chaussures. Les joueurs 1 et 2 ont chacun une chaussure gauche et le joueur 3 a une chaussure droite. La fonction de récompense de ce jeu coopératif compte le nombre de paires de chaussures dont on dispose en fonction des joueurs présents :

$$R(G) = \begin{cases} 1 & \text{si } G \in \{\{2, 3\}, \{1, 2\}, \{1, 2, 3\}\} \\ 0 & \text{sinon} \end{cases}$$

Calculer l'importance, au sens des valeurs de Shapley, de chacun des trois joueurs.

Exercice 4 : Mesure de la qualité des explications (5 points)

On considère un univers à 3 critères et la capacité définie par les poids suivants (les conditions aux limites ne sont pas rappelées)

A	$\{1\}$	$\{2\}$	$\{3\}$	$\{1, 2\}$	$\{1, 3\}$	$\{2, 3\}$
$\mu(A)$	$1/2$	$1/3$	$1/3$	$1/2$	1	$2/3$

1. Calculer la valeur de l'intégrale de Choquet induite par cette capacité pour les 4 cas suivants, où les évaluations des critères sont comprises entre 0 et 20 : $x_A = (15, 18, 6)$, $x_B = (15, 6, 18)$, $x_C = (6, 15, 18)$ et $x_D = (15, 15, 15)$.
2. Indiquer la meilleure option parmi A , B , C et D .
3. Tracer, dans le plan (x_1, x_2) , les lignes de niveaux de $C_\mu((x_1, x_2, 6))$ pour les cas où $x_1 \geq 6$ et $x_2 \geq 6$.
4. On souhaite évaluer la qualité d'une explication par exemple contre-factuel en considérant (i) la distance entre l'exemple contre-factuel e et la donnée x dont la prédiction est à expliquer, (ii) le réalisme de e et (iii) la simplicité de l'explication
 - (a) Pour chacun de ces critères, indiquer pourquoi on peut considérer qu'il joue un rôle dans la qualité de l'explication et comment on peut le quantifier.
 - (b) Quel est l'intérêt éventuel d'une intégrale de Choquet dans ce cadre ? Quels reproches éventuels peut-on lui faire ? Comment peut-on la mettre en œuvre ?

Exercice 5 : Intelligibilité et personnalisation (3 points)

On considère deux utilisateurs dont la tolérance au retard et la compréhension des imprécisions temporelles diffèrent : pour Clodomir, *environ 20 minutes* est un sous-ensemble flou triangulaire de support $[15, 25]$; pour Childebert, *environ 20 minutes* est un sous-ensemble flou trapézoïdal de noyau $[15, 30]$ et de support $[10, 60]$.

1. Représenter graphiquement les fonctions d'appartenance f_d et f_{ch} de ces deux sous-ensembles flous.
2. On considère un jour de grand départ, et donc d'embouteillages à partir d'une certaine heure, qui vont augmenter la durée du trajet : pour un départ à t minutes après 17h, la durée du trajet en minutes est estimée à

$$\tau(t) = \begin{cases} 30 & \text{si } t \leq 20 \\ (t - 20)^2 + 30 & \text{sinon} \end{cases}$$

Calculer la durée du trajet estimée par Clodomir et Childebert, qui partent environ 20 minutes après 17h, et l'heure d'arrivée approximative qu'ils peuvent annoncer respectivement.

Il est demandé une représentation graphique des résultats, avec justification, mais pas nécessairement une résolution analytique.