

Durée 1h30

seul document autorisé : feuille A4 manuscrite
tout support électronique interdit
Le barème n'est donné qu'à titre indicatif.

Exercice 1 : Interprétabilité par la logique floue (4 points)

1. On considère la fonction d'implication floue de Brouwer-Gödel

$$\begin{aligned} op_{\rightarrow}^{BG} : [0, 1] \times [0, 1] &\longrightarrow [0, 1] \\ (u, v) &\longmapsto \begin{cases} 1 & \text{si } u \leq v \\ v & \text{sinon} \end{cases} \end{aligned}$$

Pourquoi peut-elle être considérée comme généralisant l'implication binaire classique ?

2. On considère la règle floue

Si x est entre 6 et 12 environ, alors y est entre 20 et 30 environ

où la prémisse est représentée par le sous-ensemble flou trapézoïdal de support $[2, 15]$ et de noyau $[6, 12]$ et la conclusion par le sous-ensemble flou trapézoïdal asymétrique de support $[10, 35]$ et de noyau $[20, 30]$.

En utilisant l'implication floue de Brouwer-Gödel rappelée ci-dessus et l'opérateur de MPG T_{op} de Zadeh défini par $T_{op}(u, v) = \min(u, v)$, calculer analytiquement le résultat obtenu par Modus Ponens Généralisé pour le fait $x = 5$ et représenter graphiquement la règle, le fait et le résultat obtenu.

3. En quoi peut-il être considéré comme plus interprétable que le résultat obtenu par la logique classique ?

Exercice 2 : Raisonnement abductif : diagnostic de panne (3 points)

On considère un système pouvant présenter un dysfonctionnement. Le raisonnement est effectué en *logique propositionnelle*, sous forme clausale.

Atomes propositionnels.

- **cfg** : erreur de configuration
- **cpd** : composant interne défaillant
- **ano** : anomalie détectée
- **alr** : alerte émise
- **stb** : système stable après redémarrage

Les *abducibles* sont :

$$\mathcal{A} = \{\text{cfg}, \text{cpd}\}.$$

Théorie clausale. La théorie Σ est composée des clauses suivantes :

- **C1** : $\neg \text{cfg} \vee \text{ano}$
- **C2** : $\neg \text{cpd} \vee \text{ano}$
- **C3** : $\neg \text{ano} \vee \text{alr}$
- **C4** : $\neg \text{cpd} \vee \neg \text{stb}$
- **C5** : $\neg \text{cfg} \vee \text{stb}$

Observations. On considère successivement les observations suivantes :

$$O_1 = \text{alr} \quad O_2 = \text{alr} \wedge \text{stb}.$$

Questions.

1. Question de cours. Donner la définition d'une hypothèse abductive minimale H expliquant O selon la théorie Σ et l'ensemble d'abducibles $\mathcal{A}$ (caractérisation en terme d'inférence).
2. En utilisant la *résolution inversée*, déterminer toutes les *hypothèses abductives minimales* expliquant l'observation O_1 . Détailler les étapes en précisant les conséquences que vous calculez (et lesquelles sont éliminées et pourquoi).
3. En utilisant les résultats précédents, faire de même pour l'observation O_2 .

Exercice 3 : Equité (fairness) (3 points)

1. Donnez (le nom et) la définition de trois biais différents que l'on peut s'attendre à trouver en apprentissage automatique.
2. Expliquez le but de la formule suivante $\mathbb{P}\{\hat{Y}|S, Y = 1\} = \mathbb{P}\{\hat{Y}|Y = 1\}$, où Y est la classe réelle, $\hat{Y}$ la classe prédite et S l'attribut binaire protégé. À quel type d'équité se raccroche-t-elle ?
3. Voici un jeu de données (synthétiques et fictives) utilisé pour apprendre un classifieur permettant de voir si une personne est à risque d'obésité (variable binaire) à partir de sa taille (en cm) et de son poids (kg). Le genre (H ou F) est un attribut protégé qui ne sera pas utilisé pour apprendre le classifieur.

Taille	Poids	Genre	Risque
172	77	H	0
178	74	H	0
182	82	H	0
170	80	H	1
174	88	H	1
176	90	H	1
178	86	H	1
178	90	H	1
180	100	H	1
182	94	H	1
184	94	H	1
186	90	H	1
164	67	F	0
164	68	F	0
168	70	F	0
163	74	F	1

- (a) Etant donné les données ci-dessus, quels biais vous semblent être présents et quelles conséquences peuvent-ils amener ?
- (b) Une *regression logistique* est apprise pour séparer les cas à risque des cas non à risque. Proposez une manière de réduire l'impact des biais.

Exercice 4 : Pot pourri (10 points)

Les questions sont liées aux séances d'exposés. Les réponses attendues doivent être synthétiques, précises et argumentées.

1. Que vise à mesurer la notion de fidélité des explications ? En quoi est-elle particulièrement importante dans le cadre des explications générées par les LLM (*self-explanations*) ? Comment peut-on la mesurer ? Donner des exemples concrets.
2. Quels critères sociétaux ou humains doivent être pris en compte dans l'évaluation des explications ?
3. Quelles peuvent être les limites des explications générées par SHAP ?
4. Etant donné une donnée x classée par f dans la classe c , un *semi-factuel* est une donnée x' qui diffère de x mais est également classée par f dans la classe c . Quelles sont les contraintes que doit vérifier x' pour pouvoir être considérée comme une explication ? Comment peut-on les quantifier ?

5. Dans quels cas et comment les auto-encodeurs, notamment parcimonieux (*Sparse Auto-Encoder*), peuvent-ils être utilisés pour générer des explications? Quels peuvent être les avantages qu'ils offrent?
6. Quels sont les problèmes de localité et de corrélation entre concepts que peuvent poser les explications par concept?
7. La figure ci-dessous (version couleur projetée), tirée de l'article *Towards more faithful natural language explanation using multi-level contrastive learning in VQA*, de Lai et al, AAAI24, représente l'architecture du système de génération d'explication textuelle pour un système de réponse à des requêtes visuelles, basé sur un principe d'apprentissage contrastif multi-niveaux (*Multi-Level Contrastive Learning*).

Elle est constituée d'un modèle vision-langage (*vision-language model*) incluant une stratégie de génération d'explication textuelle de type *Chain-of-thought* et un réseau d'apprentissage contrastif multi-niveaux (*multi-level contrastive learning network*) comportant trois niveaux : sémantique (*semanticCL*), image (*imageCL*) et instance (*instanceCL*).

Commenter le rôle de chacun des modules en examinant leurs paramètres d'entrée.

